

STT 모델 파인튜닝 및 경량화

3.x 음성 인식(STT) 모델

3.x.1 베이스 모델 선정

오프라인 환경에서 동작하는 한국어 음성 인식을 위해 OpenAI의 Whisper-Small 모델(244M 파라미터)을 채택하였다. 다국어 사전학습 모델임에도 한국어 인식 성능이 우수하며, 노트북 CPU 환경에서도 실시간 추론이 가능한 적정 크기를 갖추고 있다.

3.x.2 학습 데이터

AI Hub의 「한국어 아동 음성 데이터」 (데이터셋 ID: 011)를 활용하였다. 본 데이터셋은 만 7-12세 아동의 발화로 구성되어 있으며, 정형 발화(`kor_formatted`)와 자유 발화(`kor_free`) 두 가지 유형을 포함한다.

구분	샘플 수	용도
Training	50,000	학습
Validation	2,000	검증

3.x.3 파인튜닝 방법

연산 자원을 절약하기 위해 LoRA(Low-Rank Adaptation) 기법을 적용하여 전체 파라미터 중 1.44% (약 354만 개)만 학습하였다. Whisper의 attention 모듈(`q_proj`, `k_proj`, `v_proj`, `out_proj`)에 LoRA 어댑터를 삽입하였으며, 주요 하이퍼파라미터는 다음과 같다.

- LoRA rank (r): 16, alpha: 32, dropout: 0.05
- 학습률: 1e-5 (linear schedule, warmup 200 steps)
- 배치 크기: 32 (8 × gradient accumulation 4)
- 학습 에폭: 3
- Optimizer: AdamW (weight decay 0.01)

학습 시 오디오를 사전 전처리 없이 TAR 아카이브에서 직접 읽어들이는 on-the-fly 방식을 채택하여 디스크 사용량을 최소화하였다.

3.x.4 경량화

학습된 LoRA 가중치를 베이스 모델에 병합한 후, CTranslate2를 이용하여 INT8 양자화된 형태로 변환하였다. 이를 통해 노트북 CPU 환경에서 faster-whisper 엔진을 통한 효율적인 추론이 가능하다.

3.x.5 평가 결과

학습에 사용되지 않은 Validation set에서 2,000개 샘플을 추출하여 노트북 CPU 환경(faster-whisper, INT8)에서 평가하였다. 평가 지표는 CER(Character Error Rate), WER(Word Error Rate), 추론 지연

시간(latency), 실시간 계수(RTF, Real-Time Factor)를 포함한다.

표 X. 베이스 모델 vs 파인튜닝 모델 성능 비교 (VAD OFF, 2,000 샘플)

지표	Whisper-Small (Base)	Whisper-Small + LoRA	개선폭
평균 CER	11.94%	9.64%	-2.30%p (19.3%↓)
평균 WER	32.04%	29.56%	-2.48%p
중양값 CER	7.69%	6.67%	-1.02%p
CER 표준편차	16.82%	11.37%	-5.45%p
평균 지연시간	3.522초	2.476초	-29.7%
평균 RTF	0.655x	0.451x	-31.1%
평균 RAM 사용량	406.4 MB	430.7 MB	+5.9%

파인튜닝을 통해 한국어 아동 음성에 대한 인식 정확도가 CER 기준 19.3% 상대 개선되었으며, 특히 CER 표준편차가 16.82%에서 11.37%로 크게 감소하여 모델 출력의 일관성이 향상되었음을 확인하였다. 또한 추론 지연시간이 약 30% 단축되었는데, 이는 도메인 적응을 통해 모델이 더 정확하고 간결한 출력을 생성하면서 디코딩 단계가 단축된 결과로 해석된다.

작성 시 주의: 위 결과는 011 데이터셋 in-domain 평가이며, 다른 도메인(자연 대화, 성인 음성 등)에서의 일반화 성능은 향후 연구 과제로 남는다는 점을 limitations 섹션에 명시 필요.